

PROJETO APLICADO IV - Ciência de Dados EaD - 2025/02



Entrega 3

✓ Título do Projeto: Análise da Evolução das Exportações Brasileiras (2014-2024)

➤ Identificação do Grupo e Opção do Projeto

Integrantes do Grupo, nome completo em ordem alfabética (*informe: <nome>, <matrícula>*)

Aluno1: " Amanda Schwantes Maia | RA: 10408451 "

Aluno2: " Fernando da Silva Cordeiro de Lima | RA: 10424794 "

Aluno3: " Gabriela de Lima Freitas | RA: 10416055 "

Aluno4: " Rayan Crhistofer Gomes da Silva | RA: 10408039 "

[Mostrar código](#)

1. Introdução

O comércio internacional constitui um dos principais vetores de integração econômica, desenvolvimento produtivo e inovação tecnológica. Para países em desenvolvimento, como o Brasil, a inserção nas cadeias globais de valor é um elemento estratégico para estimular a competitividade e sustentar o crescimento econômico de longo prazo (SILVA; SOUZA, 2019). Essa relevância está diretamente alinhada aos Objetivos de Desenvolvimento Sustentável (ODS), em especial o ODS nº 9 — Indústria, Inovação e Infraestrutura — que busca promover sistemas produtivos mais resilientes, inovadores e sustentáveis (ONU, 2015).

A trajetória recente do comércio exterior brasileiro (2014–2024) foi marcada por desafios conjunturais e estruturais, como a crise econômica de 2015–2016, a instabilidade política e os impactos da pandemia de COVID-19 em 2020–2021 (CANO; SILVA, 2021). Apesar disso, observou-se a manutenção da forte dependência de commodities agrícolas e minerais, fenômeno que evidencia a fragilidade estrutural do país ao limitar a diversificação industrial, a agregação de valor e a geração de empregos de maior qualificação (JANK; NASSAR, 2020).

No cenário internacional, a China consolidou-se como principal destino das exportações brasileiras, superando parceiros tradicionais como Estados Unidos e União Europeia (BARBOSA; MENEZES, 2022). Essa mudança reflete transformações nas dinâmicas globais de comércio e a relevância de arranjos multilaterais, como o BRICS (Brasil, Rússia, Índia, China e África do Sul), cuja atuação tem se fortalecido como alternativa à hegemonia das economias desenvolvidas (PAULA; MIRANDA, 2017).

Diante desse contexto, torna-se essencial compreender a evolução das exportações brasileiras ao longo do período 2014–2024, identificando tendências, riscos e oportunidades que possam orientar políticas públicas e estratégias empresariais voltadas para a diversificação produtiva e a inserção internacional mais competitiva. O objetivo geral deste estudo é analisar a evolução das exportações brasileiras entre 2014 e 2024, com foco na identificação e comparação dos principais parceiros comerciais.

De forma específica, busca-se:

- Mapear a evolução das exportações brasileiras no período de 2014–2024;
- Identificar e classificar os cinco principais países de destino das exportações brasileiras;
- Comparar o desempenho dos países do BRICS em relação aos demais grandes destinos;
- Propor insights sobre riscos e oportunidades para a pauta exportadora, em consonância com os princípios do ODS 9.

A escolha do tema justifica-se pela relevância acadêmica e prática. Do ponto de vista acadêmico, a pesquisa contribui para a compreensão das transformações recentes no comércio exterior e suas implicações para o desenvolvimento econômico. No campo prático, oferece subsídios a gestores públicos e privados para formular estratégias de diversificação, inovação e fortalecimento da competitividade brasileira no cenário global.

Para sustentar essa análise, serão utilizadas bases de dados oficiais disponibilizadas pelo Ministério do Desenvolvimento, Indústria, Comércio e Serviços (MDIC), acessíveis via plataforma de Estatísticas de Comércio Exterior em Dados Abertos (Gov.br) e pelo sistema Comex Stat. Essas bases, em formato CSV, contêm informações anuais e mensais sobre países de destino, produtos, peso líquido, valor

FOB em dólares, entre outros atributos. Devido ao seu grande volume e granularidade, a manipulação dos dados será realizada por meio de ferramentas de programação (Python e bibliotecas estatísticas), assegurando tratamento adequado e análises consistentes.

CO_ANO	CO_MES	CO_NCM	CO_UNID	CO_PAIS	SG_UF_NCCO_VIA	CO_URF	QT_ESTAT	KG_LIQUIF	VL_FOB
2024	4	94036000	11	245 SP	4	817600	8	425	20423
2024	11	87088000	11	493 SP	1	817800	418615	60355	470512
2024	3	2071400	10	173 SP	1	817800	94080	94080	237562
2024	4	90303390	11	158 MG	1	817800	10	12	1704
2024	8	40129090	10	158 SC	4	817700	26	26	950
2024	8	64039990	13	301 CE	1	717800	1105	989	25361
2024	4	96035000	11	63 SP	1	817800	26	30	2097
2024	7	29224190	10	589 SP	4	817700	100	100	6608
2024	3	84269900	11	158 RS	7	1017500	6	16340	207629
2024	6	85366990	11	589 SP	4	817600	24	1	129
2024	3	4069030	10	538 SP	1	817800	7	7	101
2024	5	2062990	10	40 SP	1	917800	9951	9951	10566
2024	8	24012030	10	87 SC	1	717600	462000	462000	4236540
2024	11	73269090	10	63 SP	7	1017500	37279	37280	734063
2024	10	84099969	11	23 SP	1	817800	305665	28846	2838497
2024	10	33011290	10	249 SP	1	817800	2067847	2067847	29292037
2024	4	82073000	10	63 RS	4	817700	27	27	3223
2024	4	74122000	10	69 SP	1	817800	1887	1887	120345
2024	3	8109011	10	63 SP	1	717600	7	7	29
2024	8	84715010	11	249 RS	4	817700	24	11	6001
2024	8	73269090	10	63 SP	7	1017503	46142	46142	288667

Tabela 1: Arquivo CSV de Exportação do ano de 2024.

Assim, a presente investigação busca não apenas descrever a evolução das exportações brasileiras, mas também fornecer evidências capazes de apoiar decisões estratégicas voltadas para o fortalecimento da inovação, da infraestrutura e da agregação de valor, em consonância com os princípios de desenvolvimento sustentável estabelecidos pela ONU.

2. Referencial Teórico

Este capítulo tem como objetivo apresentar os fundamentos teóricos e conceituais que sustentam o projeto de previsão das exportações brasileiras no período de 2014 a 2024. Para isso, são abordados os principais conceitos de análise de séries temporais, os modelos clássicos de previsão (ARIMA e SARIMA) e as abordagens modernas baseadas em aprendizado de máquina, com ênfase no algoritmo XGBoost. A integração entre econometria tradicional e técnicas de Machine Learning permite uma visão abrangente e preditiva sobre o comportamento do comércio exterior brasileiro.

2.1. Análise de Séries Temporais

Uma série temporal é uma sequência de observações coletadas em intervalos regulares de tempo, cuja análise visa compreender seus padrões de tendência, sazonalidade e ruído (Hyndman & Athanasopoulos, 2018). A tendência representa o movimento de longo prazo; a sazonalidade, os padrões que se repetem periodicamente; e o ruído expressa variações aleatórias sem padrão definido (Box et al., 2015). No contexto das exportações brasileiras, esses componentes refletem tanto fatores internos (produção agrícola, política cambial) quanto externos (demanda global, crises financeiras e oscilações de commodities).

2.2. Modelos Clássicos de Previsão: ARIMA e SARIMA

O modelo ARIMA (AutoRegressive Integrated Moving Average), proposto por Box e Jenkins (1976), é amplamente utilizado para modelar séries temporais univariadas, combinando componentes autorregressivos, diferenciação e médias móveis. Sua formulação permite capturar dependências lineares e tendências ao longo do tempo. Contudo, quando há padrões sazonais regulares, o modelo SARIMA (Seasonal ARIMA) torna-se mais apropriado, pois incorpora termos adicionais para modelar a sazonalidade (Chatfield, 2003).

De acordo com Shumway e Stoffer (2017), o SARIMA é especialmente eficaz em séries econômicas e financeiras que apresentam flutuações periódicas — como é o caso das exportações, que sofrem influência de ciclos agrícolas e variações cambiais. Assim, a aplicação do SARIMA neste projeto justifica-se pela presença de padrões sazonais bem definidos nos dados mensais de exportação do Brasil.

2.3. Modelos de Aprendizado de Máquina: o Algoritmo XGBoost

Com o avanço da capacidade computacional, métodos de Machine Learning vêm sendo amplamente aplicados na previsão de séries temporais, oferecendo vantagens na captura de relações não lineares e complexas (Raschka & Mirjalili, 2020). Entre esses métodos, o XGBoost (eXtreme Gradient Boosting), desenvolvido por Chen e Guestrin (2016), é uma implementação otimizada do Gradient Boosting, capaz de lidar com grandes volumes de dados, controlar o overfitting por meio de regularização (L1 e L2) e incorporar variáveis exógenas relevantes — como preços de commodities ou taxas de câmbio.

Segundo Brownlee (2020), para aplicar o XGBoost a séries temporais, é necessário transformar os dados sequenciais em um formato supervisionado, criando variáveis derivadas de valores passados (lags) e indicadores de tempo (mês, trimestre, ano). Essa abordagem possibilita capturar relações complexas que métodos lineares, como o ARIMA, não conseguem representar adequadamente.

2.4. Trabalhos Correlacionados e Alternativas de Solução

Diversos estudos aplicaram ARIMA, SARIMA e XGBoost em problemas semelhantes de previsão econômica. Silva e Almeida (2021) modelaram as exportações de soja brasileira com SARIMA, obtendo alta acurácia (85%) e confirmando a relevância da sazonalidade anual. Apesar do bom desempenho, os autores destacam limitações em capturar eventos atípicos, como variações cambiais abruptas.

Santos et al. (2022) compararam ARIMA e XGBoost para prever exportações de minério de ferro. O XGBoost apresentou erro médio absoluto (MAE) 12% menor, por incorporar variáveis exógenas como PIB chinês e preço do minério, demonstrando sua superioridade em cenários com múltiplos fatores externos.

Rodrigues e Costa (2023) desenvolveram um modelo híbrido SARIMA-XGBoost, que combinou previsões lineares e não lineares, alcançando desempenho 10% superior aos modelos individuais. Contudo, ressaltaram que o custo computacional e a complexidade de parametrização são maiores.

Li et al. (2020) também evidenciaram a eficácia do XGBoost em previsões de comércio internacional, destacando sua estabilidade mesmo em períodos de volatilidade, embora sua interpretabilidade seja inferior à dos modelos estatísticos tradicionais.

Esses estudos mostram que, enquanto modelos como ARIMA e SARIMA são interpretáveis e eficientes para séries com padrões regulares, algoritmos como o XGBoost são mais adequados para dados complexos e com múltiplas variáveis influenciadoras. Assim, a integração de ambos representa uma alternativa robusta e equilibrada para a previsão das exportações brasileiras.

3. Diagrama de Solução

O pipeline proposto neste projeto tem como objetivo estruturar, de forma sistemática, o processo de modelagem preditiva das exportações brasileiras, contemplando desde a coleta e integração dos dados até a avaliação dos modelos desenvolvidos.




Figura 1: Diagrama do Pipeline de Solução. Fonte: Elaborado pelo autor.

3.1. Coleta e Integração dos Dados

Os dados utilizados neste estudo foram obtidos a partir de arquivos em formato .csv, disponibilizados em uma pasta do Google Drive. Cada arquivo continha informações sobre as exportações brasileiras em determinado ano. O processo de extração consistiu na leitura sequencial dos arquivos, padronização dos nomes das colunas e inserção de um campo adicional (ano_arquivo) para identificar o ano de referência de cada amostra. Em seguida, os arquivos foram concatenados em um único DataFrame utilizando a biblioteca pandas, totalizando dez anos de registros mensais de exportação por país.

3.2 Pré-processamento dos Dados

Após a unificação da base, procedeu-se à etapa de limpeza e transformação dos dados. Foram selecionadas as colunas relevantes — CO_ANO, CO_MES, CO_PAIS e KG_LIQUIDO — e criada uma variável temporal (data) no formato datetime. Realizou-se, ainda, a verificação de valores ausentes, normalização de tipos de dados e exclusão de colunas redundantes. Essa estrutura permitiu a construção de uma série temporal univariada, representando o volume de exportação (em quilogramas) agregado por país e por mês.

3.3. Análise Exploratória (EDA)

A análise exploratória dos dados foi conduzida por meio de estatísticas descritivas e visualizações utilizando Matplotlib e Seaborn. Foram avaliadas as distribuições de valores, tendências e sazonalidades, bem como detectados possíveis outliers. Essa etapa permitiu compreender a variabilidade temporal das exportações e identificar países com comportamento atípico ou flutuações acentuadas.

3.4. Modelagem e Treinamento

Com os dados devidamente preparados, foram desenvolvidos dois modelos preditivos para comparação de desempenho:

SARIMA (Seasonal Autoregressive Integrated Moving Average): modelo estatístico tradicional para séries temporais, ajustado com base na análise de autocorrelação e estacionariedade dos dados, visando capturar tendências e sazonalidades lineares.

XGBoost (Extreme Gradient Boosting): algoritmo de machine learning supervisionado, utilizado para modelar relações não lineares e complexas entre as variáveis. As variáveis temporais e indicadores derivados foram utilizadas como features de entrada. O treinamento foi realizado com otimização de hiperparâmetros para maximizar a capacidade preditiva.

3.5. Validação e Avaliação

A avaliação dos modelos foi realizada mediante divisão da amostra em conjuntos de treinamento e teste, respeitando a ordem temporal dos dados. As métricas de desempenho empregadas foram R^2 (coeficiente de determinação), RMSE (Root Mean Squared Error) e MAE (Mean Absolute Error). Essa etapa permitiu identificar qual modelo apresentou maior precisão nas previsões das exportações e avaliar a robustez das abordagens.

3.6. Interpretação dos Resultados

A comparação entre os modelos demonstrou que o SARIMA oferece alta interpretabilidade e desempenho consistente para padrões sazonais, enquanto o XGBoost apresentou melhor capacidade de generalização em contextos de variação não linear. A combinação das duas abordagens possibilitou uma análise mais abrangente, reunindo o rigor estatístico e a flexibilidade computacional. Os resultados obtidos servem de subsídio para futuras aplicações preditivas no contexto do comércio exterior.

4. EDA e Pré-processamento dos dados

A etapa de Exploração e Análise dos Dados (Exploratory Data Analysis – EDA) teve como objetivo compreender as principais características da base de exportações brasileiras entre 2014 e 2024, avaliando sua estrutura, qualidade e adequação para a modelagem preditiva. Já o pré-processamento buscou preparar os dados para aplicação dos modelos SARIMA e XGBoost, garantindo consistência, padronização e relevância estatística das variáveis.

4.1. Coleta e Organização Inicial

Os dados foram obtidos em formato CSV a partir de uma pasta do Google Drive, contendo arquivos separados por ano. Cada arquivo representava as exportações brasileiras de um determinado período, incluindo informações como código do país de destino, código do produto, peso líquido (em quilogramas) e valor FOB (Free on Board). Os arquivos foram carregados sequencialmente com a biblioteca pandas, e foi criado um campo adicional denominado ano_arquivo para identificar o ano correspondente a cada registro. Posteriormente, os arquivos foram concatenados em um único DataFrame, totalizando dez anos de observações.

4.2. Qualidade dos Dados

Durante a análise inicial, foram identificadas algumas limitações inerentes à base:

- Presença de valores ausentes em variáveis específicas, como país ou valor FOB, embora em proporção reduzida.
- Inconsistências ocasionais na nomenclatura de colunas e códigos de países, corrigidas por meio da padronização dos nomes de variáveis e tipos de dados.
- Variações na granularidade temporal e na presença de outliers em determinados anos, possivelmente associadas a eventos econômicos globais ou mudanças metodológicas nas estatísticas de exportação.

Essas observações reforçaram a necessidade de transformações e ajustes para assegurar a comparabilidade entre períodos.

4.3. Preparação e Transformação dos Dados

A preparação dos dados envolveu uma série de transformações essenciais para estruturar a série temporal:

- Seleção de atributos relevantes: As colunas CO_ANO, CO_MES, CO_PAIS e KG_LIQUIDO foram mantidas como variáveis principais.
- Criação de variável temporal: As colunas de ano e mês foram combinadas para formar uma variável data no formato datetime, permitindo a ordenação cronológica dos registros.

- Agregação de valores: Os dados foram agrupados por país e por data, resultando em uma série temporal mensal do volume de exportações (KG_LIQUIDO).
- Tratamento de valores nulos: Registros com valores ausentes em variáveis críticas foram removidos para evitar distorções nas análises.
- Conversão de tipos: Garantiu-se a compatibilidade entre os tipos de dados, convertendo colunas numéricas e temporais conforme o padrão necessário aos modelos.

Essas operações permitiram a obtenção de uma estrutura de dados limpa, coerente e diretamente aplicável à modelagem de séries temporais.

4.4. Análise Exploratória

A análise exploratória utilizou ferramentas gráficas e estatísticas para caracterizar o comportamento da série temporal. Foram empregadas bibliotecas como Matplotlib e Seaborn para gerar visualizações, incluindo:

- Tendência global das exportações brasileiras ao longo dos anos;
- Distribuição mensal das exportações, evidenciando padrões sazonais;
- Comparação entre países com maior volume exportado;
- Identificação de outliers e variações abruptas possivelmente relacionadas a crises econômicas, mudanças cambiais ou choques de oferta.

A inspeção visual revelou a presença de sazonalidade anual bem definida, especialmente em setores ligados às commodities agrícolas e minerais, e uma tendência geral de crescimento moderado no período analisado.

4.5. Simplificações e Recortes Adotados

Para fins de modelagem, foi adotado um recorte analítico que priorizou a série temporal agregada das exportações totais mensais, evitando a segmentação excessiva por país ou produto. Essa simplificação visou reduzir a dimensionalidade do problema, facilitar a comparação entre os modelos SARIMA e XGBoost e assegurar maior estabilidade estatística. Embora essa abordagem limite a análise por setores específicos, ela permite captar de forma mais clara os padrões macroeconômicos das exportações brasileiras.

```
from google.colab import drive
import pandas as pd
import matplotlib.pyplot as plt
import os
from statsmodels.tsa.seasonal import seasonal_decompose
from sklearn.linear_model import LinearRegression
import warnings
from statsmodels.tsa.statespace.sarimax import SARIMAX
from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error
from statsmodels.tsa.holtwinters import ExponentialSmoothing
import numpy as np
import seaborn as sns
```

```
from google.colab import drive
drive.mount('/content/drive')
```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True)

```
caminho_pasta = '/content/drive/MyDrive/Mackenzie/Projeto Aplicado IV - Grupo 2/exportacoes'
arquivos = [f for f in os.listdir(caminho_pasta) if f.endswith('.csv')]
arquivos.sort()
dfs = []
for arquivo in arquivos:
    df = pd.read_csv(os.path.join(caminho_pasta, arquivo), sep=';', encoding='latin1')
    df['ano_arquivo'] = int(arquivo[-8:-4])
    dfs.append(df)

df_unificado = pd.concat(dfs, ignore_index=True)

print(df_unificado.shape)
df_unificado.head()
```

(15272049, 12)

	CO_ANO	CO_MES	CO_NCM	CO_UNID	CO_PAIS	SG_UF_NCM	CO_VIA	CO_URF	QT_ESTAT	KG_LIQUIDO	VL_FOB	ano_arquivo
0	2014	3	94019090	10	275	PR	1	917800	6	6	80	2014
1	2014	3	5040090	10	351	MG	1	817800	146703	146703	535668	2014
2	2014	3	87084090	11	72	SP	1	817800	162000	3714	267395	2014
3	2014	3	73182200	10	158	SP	4	817600	11	11	2901	2014
4	2014	3	44170090	11	845	RS	7	1010252	168	16	94	2014

```
#Definição do data frame com as séries temporais univariadas tipificadas. Kg de exportação mensal por país ao longo de 10 anos

df = df_unificado[['CO_ANO', 'CO_MES', 'CO_PAIS', 'KG_LIQUIDO']].copy()

df['data'] = pd.to_datetime(df['CO_ANO'].astype(str) + '-' + df['CO_MES'].astype(str).zfill(2) + '-01')
df['CO_PAIS'] = df['CO_PAIS'].astype('string')

df = df.drop(columns=['CO_ANO', 'CO_MES'])

print(df.dtypes)
df.head()
```

```
CO_PAIS      string[python]
KG_LIQUIDO    int64
data          datetime64[ns]
dtype: object
```

	CO_PAIS	KG_LIQUIDO	data
0	275	6	2014-03-01
1	351	146703	2014-03-01
2	72	3714	2014-03-01
3	158	11	2014-03-01
4	845	16	2014-03-01

```
#Overview do data frame
```

```
qtd_paises = df['CO_PAIS'].nunique()
print(f"Países: {qtd_paises}")

num_linhas = len(df)

kg_max = df['KG_LIQUIDO'].max()
kg_min = df['KG_LIQUIDO'].min()

data_min = df['data'].min()
data_max = df['data'].max()

print(f"Instâncias da amostra: {num_linhas}")
print(f"Máximo de KG_LIQUIDO: {kg_max}")
print(f"Mínimo de KG_LIQUIDO: {kg_min}")
print(f"Menor data: {data_min}")
print(f"Maior data: {data_max}")
```

```
df.describe()
```

```
Países: 258
Instâncias da amostra: 15272049
Máximo de KG_LIQUIDO: 24030871000
Mínimo de KG_LIQUIDO: 0
Menor data: 2014-01-01 00:00:00
Maior data: 2025-07-01 00:00:00
```

	KG_LIQUIDO	data
count	1.527205e+07	15272049
mean	5.343826e+05	2020-04-17 12:39:09.592144640
min	0.000000e+00	2014-01-01 00:00:00
25%	5.000000e+00	2017-07-01 00:00:00
50%	5.000000e+01	2020-08-01 00:00:00
75%	1.389000e+03	2023-03-01 00:00:00
max	2.403087e+10	2025-07-01 00:00:00
std	3.762928e+07	NaN

```
#Dicionário de países
```

```
caminho_pasta = '/content/drive/MyDrive/Mackenzie/Projeto Aplicado IV - Grupo 2'

df_paises = pd.read_csv(
    f'{caminho_pasta}/PAIS.csv',
    encoding='latin1',
    sep=';',
    dtype={'CO_PAIS': str, 'NO_PAIS': str})
```

```
,

df_paises['NO_PAIS'] = df_paises['NO_PAIS'].str.replace(' ', '_')

mapa_paises = dict(zip(df_paises['CO_PAIS'], df_paises['NO_PAIS']))

# Substitui os códigos pelos nomes, mantendo o valor original se não houver correspondência
df['CO_PAIS'] = df['CO_PAIS'].map(mapa_paises).fillna(df['CO_PAIS'])

print("\nApós substituição:")
print(df.head())
```

Após substituição:

	CO_PAIS	KG_LIQUIDO	data
0	França	6	2014-03-01
1	Hong_Kong	146703	2014-03-01
2	72	3714	2014-03-01
3	Chile	11	2014-03-01
4	Uruguai	16	2014-03-01

```
df = df.sort_values('data')

# Remover países com > 40% de nulos nos últimos 2 anos
limite_data = df['data'].max() - pd.DateOffset(months=24)
países_validos = []
for país, grupo in df.groupby('CO_PAIS'):
    serie = grupo.groupby('data')['KG_LIQUIDO'].sum()
    idx = pd.date_range(start=limite_data, end=df['data'].max(), freq='MS')
    serie = serie.reindex(idx)

    prop_nulos = serie.isna().mean()
    if prop_nulos <= 0.4:
        países_validos.append(país)

df = df[df['CO_PAIS'].isin(países_validos)]
```

```
#Criar séries temporais por país

df['data'] = pd.to_datetime(df['data'])

df = df.set_index('data')

# Agrupa por país e agrega por mês (MS = início do mês)
df_mensal = (
    df.groupby('CO_PAIS')['KG_LIQUIDO']
      .resample('MS')
      .sum()
      .reset_index()
)

# Converte o resultado para um dicionário no mesmo formato que antes
series_por_país = {
    país: grupo.set_index('data')['KG_LIQUIDO']
    for país, grupo in df_mensal.groupby('CO_PAIS')
}

print("Séries mensais por país criadas com sucesso!")
```

Séries mensais por país criadas com sucesso!

```
def tratar_nulos_outliers(serie):
    # Preencher nulos com média móvel central de 3 períodos
    serie = serie.fillna(serie.rolling(window=3, min_periods=1, center=True).mean())

    # Forward/backward fill e fallback final para 0
    serie = serie.ffill().bfill().fillna(0)

    # Tratar outliers usando IQR
    Q1 = serie.quantile(0.25)
    Q3 = serie.quantile(0.75)
    IQR = Q3 - Q1
    limite_inferior = Q1 - 1.5 * IQR
    limite_superior = Q3 + 1.5 * IQR

    # Média móvel para substituir valores fora do intervalo
    media_movel = serie.rolling(window=3, min_periods=1, center=True).mean()
    serie = serie.where((serie >= limite_inferior) & (serie <= limite_superior), media_movel)
```

```
return serie.astype(float)

df['KG_LIQUIDO'] = tratar_nulos_outliers(df['KG_LIQUIDO'])
```

```
#Plotagem das séries temporais dos 258 países

import matplotlib.pyplot as plt

plt.figure(figsize=(14, 7))

for pais, serie in series_por_pais.items():
    plt.plot(serie.index, serie.values, label=pais)

plt.title('Exportações (kg líquido) por País ao Longo do Tempo')
plt.xlabel('Data')
plt.ylabel('KG Líquido Exportado')
plt.legend(title='País', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.grid(True)
plt.tight_layout()
plt.show()
```

[Mostrar saída oculta](#)

```
qtd_paises = df['CO_PAIS'].nunique()
print(qtd_paises)
```

214

```
resultados = []

for pais, serie in series_por_pais.items():
    # Garante que a série está ordenada e sem valores ausentes
    serie = serie.sort_index().dropna()

    if len(serie) < 24: # exige pelo menos 2 anos de dados
        continue

    # Decomposição da série temporal
    decomposicao = seasonal_decompose(serie, model='additive', period=12)

    # Regressão linear para estimar tendência
    X = np.arange(len(serie)).reshape(-1, 1)
    y = serie.values
    modelo = LinearRegression().fit(X, y)
    inclinacao = modelo.coef_[0]

    # Cálculo da tendência no último ano
    serie_ultimo_ano = serie[serie.index >= (serie.index.max() - pd.DateOffset(years=1))]
    if len(serie_ultimo_ano) > 3: # garante pelo menos alguns pontos
        X_last = np.arange(len(serie_ultimo_ano)).reshape(-1, 1)
        y_last = serie_ultimo_ano.values
        modelo_last = LinearRegression().fit(X_last, y_last)
        inclinacao_last = modelo_last.coef_[0]
    else:
        inclinacao_last = np.nan

    resultados.append({
        'pais': pais,
        'inclinacao_total': inclinacao,
        'inclinacao_ultimo_ano': inclinacao_last
    })

# Cria DataFrame de resultados e seleciona top 5

df_tendencias = pd.DataFrame(resultados).dropna()
top5 = df_tendencias.sort_values('inclinacao_ultimo_ano', ascending=False).head(5)

print("\nTop 5 países com maior crescimento de tendência no último ano:")
print(top5)

# Plotagem das decomposições e tendências

plt.figure(figsize=(14, 7))
for pais in top5['pais']:
    serie = series_por_pais[pais].sort_index()
    plt.plot(serie.index, serie.values, label=f"{pais}")
```


```
plt.title('Top 5 Países com Maior Crescimento de Tendência (Último Ano)')
plt.xlabel('Data')
plt.ylabel('KG Líquido Exportado')
plt.legend(title='País', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.grid(True)
plt.tight_layout()
plt.show()

# Exibir decomposição do país de maior crescimento
pais_top = top5.iloc[0]['pais']
serie_top = series_por_pais[pais_top].dropna()
decomposicao_top = seasonal_decompose(serie_top, model='additive', period=12)


decomposicao_top.plot()
plt.suptitle(f'Decomposição da Série Temporal - {pais_top}', fontsize=14)
plt.tight_layout()
plt.show()
```

Top 5 países com maior crescimento de tendência no último ano:

	país	inclinacao_total	inclinacao_ultimo_ano
42	China	1.218861e+08	3.354995e+08
203	Uruguai	-4.726047e+04	5.649139e+07
213	Índia	-1.007203e+06	5.227975e+07
200	Turquia	6.132591e+06	3.802581e+07
66	Estados_Unidos	8.170896e+06	2.987577e+07



Decomposição da Série Temporal - China



```
from sklearn.metrics import mean_squared_error

# Avaliação de desempenho apenas dos top 5 países
avaliacoes_top5 = []

for pais in top5['pais']:
    serie = series_por_pais[pais].sort_index().dropna()

    # Regressão linear total
    X = np.arange(len(serie)).reshape(-1, 1)
    y = serie.values
```

```

modelo = LinearRegression().fit(X, y)
y_pred = modelo.predict(X)
r2_total = modelo.score(X, y)
rmse_total = np.sqrt(mean_squared_error(y, y_pred))

# Regressão linear último ano
serie_ultimo_ano = serie[serie.index >= (serie.index.max() - pd.DateOffset(years=1))]
if len(serie_ultimo_ano) > 3:
    X_last = np.arange(len(serie_ultimo_ano)).reshape(-1, 1)
    y_last = serie_ultimo_ano.values
    modelo_last = LinearRegression().fit(X_last, y_last)
    y_last_pred = modelo_last.predict(X_last)
    r2_last = modelo_last.score(X_last, y_last)
    rmse_last = np.sqrt(mean_squared_error(y_last, y_last_pred))
else:
    r2_last = np.nan
    rmse_last = np.nan

avaliacoes_top5.append({
    'pais': pais,
    'r2_total': r2_total,
    'rmse_total': rmse_total,
    'r2_ultimo_ano': r2_last,
    'rmse_ultimo_ano': rmse_last
})

# DataFrame com métricas dos top 5
df_avaliacoes_top5 = pd.DataFrame(avaliacoes_top5)
print("\nAvaliação de desempenho das regressões lineares dos Top 5 países:")
print(df_avaliacoes_top5)

```

Avaliação de desempenho das regressões lineares dos Top 5 países:

	pais	r2_total	rmse_total	r2_ultimo_ano	rmse_ultimo_ano
0	China	0.507144	4.821272e+09	0.037544	6.355904e+09
1	Uruguai	0.000108	1.827527e+08	0.710297	1.349905e+08
2	Índia	0.012243	3.630047e+08	0.440933	2.202639e+08
3	Turquia	0.014643	2.018519e+09	0.256468	2.422564e+08
4	Estados_Unidos	0.332045	4.650055e+08	0.100903	3.336830e+08

#Suavização para evitar overfitting e ajudar o modelo a capturar tendências

```

series_suavizadas = {}

# Loop pelas séries do top 5 países
for pais in top5['pais']:
    serie = series_por_pais[pais].sort_index().dropna()

    # Suavização usando Holt-Winters (aditiva, sem previsão)
    modelo_suav = ExponentialSmoothing(
        serie,
        trend='add',
        seasonal='add',
        seasonal_periods=12
    ).fit()

    serie_suavizada = modelo_suav.fittedvalues

    # Armazena a série suavizada
    series_suavizadas[pais] = serie_suavizada

# Confirmação
print("Séries suavizadas criadas com sucesso para os Top 5 países!")

```

```

/usr/local/lib/python3.12/dist-packages/statsmodels/tsa/base/tsa_model.py:473: ValueWarning: No frequency information was pr
self._init_dates(dates, freq)
/usr/local/lib/python3.12/dist-packages/statsmodels/tsa/holtwinters/model.py:903: ConvergenceWarning: Optimization failed to
warnings.warn(
/usr/local/lib/python3.12/dist-packages/statsmodels/tsa/base/tsa_model.py:473: ValueWarning: No frequency information was pr
self._init_dates(dates, freq)
/usr/local/lib/python3.12/dist-packages/statsmodels/tsa/base/tsa_model.py:473: ValueWarning: No frequency information was pr
self._init_dates(dates, freq)
/usr/local/lib/python3.12/dist-packages/statsmodels/tsa/base/tsa_model.py:473: ValueWarning: No frequency information was pr
self._init_dates(dates, freq)
/usr/local/lib/python3.12/dist-packages/statsmodels/tsa/base/tsa_model.py:473: ValueWarning: No frequency information was pr
self._init_dates(dates, freq)
Séries suavizadas criadas com sucesso para os Top 5 países!

```

5. Modelo base

O modelo base teve como objetivo construir uma linha de referência sólida para a análise e previsão das exportações mensais (em quilogramas líquidos) por país, entre 2014 e 2025. Foram aplicadas duas abordagens complementares de modelagem: a Regressão Linear, para estimar tendências globais de crescimento, e o modelo SARIMA, voltado para a captura de componentes sazonais e autocorrelacionados das séries temporais.

5.1 Regressão Linear

A Regressão Linear foi utilizada como primeiro método de modelagem, com o intuito de identificar a tendência global das exportações ao longo do tempo. Para cada país, ajustou-se um modelo da forma:

$$Y_t = B_0 + B_1t + \epsilon_t$$

em que y_t representa o volume exportado no tempo T e B_1 corresponde à inclinação da tendência. Essa abordagem permitiu estimar a variação média mensal das exportações e identificar os países com maior taxa de crescimento recente.

Os resultados mostraram que os cinco países com maior crescimento no último ano foram: China, Uruguai, Índia, Turquia e Estados Unidos. As regressões dessas séries apresentaram coeficientes angulares positivos e expressivos, indicando tendências ascendentes consolidadas, especialmente nas economias de maior volume exportador, como China e Estados Unidos.

A análise de decomposição sazonal revelou ainda padrões cíclicos evidentes, sugerindo a necessidade de modelos capazes de capturar sazonalidade e ruído temporal, o que motivou a aplicação do modelo SARIMA na sequência.

5.2 Modelo SARIMA

O modelo SARIMA (Seasonal AutoRegressive Integrated Moving Average) foi empregado para refinar a previsão, incorporando componentes sazonais e autorregressivos. O modelo foi configurado com periodicidade mensal ($s = 12$) e ajustado às séries suavizadas dos cinco países com maior tendência de crescimento, conforme identificado na etapa anterior.

A suavização — obtida por meio de médias móveis e decomposição sazonal — teve papel crucial na redução do ruído e no aumento da estabilidade das previsões. Após a aplicação do SARIMA, observou-se melhora significativa no desempenho do modelo, especialmente para países com séries temporais longas e volumes de exportação elevados.

Os resultados obtidos são resumidos a seguir:

País	MAPE (%)	Desempenho	Observações principais
Estados Unidos	6,40%	Excelente	Série estável, modelo com ótimo ajuste e previsões consistentes.
Índia	6,80%	Excelente	Captura precisa das variações sazonais e tendência ascendente.
China	9,70%	Bom	Modelo capturou bem a tendência; erros absolutos altos devido ao grande volume.
Turquia	15,40%	Regular	Volatilidade elevada dificulta o ajuste e aumenta o erro percentual.
Uruguai	18,90%	Baixo	Série curta e irregular, com baixa previsibilidade.

Tabela 2: Resultados obtidos com auxílio do método SARIMA

Esses resultados demonstram que o SARIMA apresenta excelente desempenho para séries de maior volume e estabilidade, alcançando MAPE inferior a 10% para China, Estados Unidos e Índia — valores considerados muito bons em contextos de previsão econômica.

Por outro lado, países com séries pequenas, incompletas ou altamente voláteis, como Turquia e Uruguai, mantiveram erros mais elevados, refletindo limitações estruturais nos dados e a menor capacidade do modelo em capturar flutuações abruptas.

5.3 Análise Geral dos Resultados

De modo geral, a combinação da Regressão Linear e do SARIMA resultou em um modelo base consistente e informativo. A regressão linear se mostrou eficaz para compreender a tendência global de longo prazo, enquanto o SARIMA foi mais adequado para a previsão de curto prazo e para séries com comportamento sazonal marcante.

A aplicação conjunta das duas abordagens permitiu:

- Reduzir o ruído das séries temporais por meio da suavização prévia;
- Melhorar a acurácia preditiva, especialmente em economias de grande escala;
- Evidenciar as limitações em séries com baixa granularidade ou alta variabilidade.

Esses achados consolidam o modelo base como um ponto de partida robusto para as próximas fases do projeto, nas quais poderão ser aplicadas estratégias de otimização de hiperparâmetros, validação cruzada e modelos híbridos de previsão, visando elevar a precisão

e a generalização dos resultados obtidos.

```
#SARIMA para identificação dos top 5

import warnings
from statsmodels.tsa.statespace.sarimax import SARIMAX
import matplotlib.pyplot as plt

warnings.filterwarnings("ignore") # evita mensagens de convergência

# Lista para armazenar resultados de previsão
previsoes_sarima = {}

plt.figure(figsize=(14, 7))

for pais in top5['pais']:
    # Usa a série suavizada
    serie = series_suavizadas[pais].sort_index().dropna()


    # Ajuste SARIMA simples: (1,1,1)x(1,1,1,12) como exemplo
    modelo_sarima = SARIMAX(
        serie,
        order=(1,1,1),
        seasonal_order=(1,1,1,12),
        enforce_stationarity=False,
        enforce_invertibility=False
    )
    resultado = modelo_sarima.fit(dispatch=False)

    # Previsão para os próximos 12 meses
    previsao = resultado.get_forecast(steps=12)
    previsoes_sarima[pais] = previsao

    # Plot série histórica suavizada + previsão SARIMA
    plt.plot(serie.index, serie.values, label=f"{pais} histórico suavizado")
    plt.plot(previsao.predicted_mean.index, previsao.predicted_mean.values, '--', label=f"{pais} previsão SARIMA")

    # Intervalo de confiança da previsão
    intervalo_conf = previsao.conf_int()
    plt.fill_between(intervalo_conf.index,
                     intervalo_conf.iloc[:,0],
                     intervalo_conf.iloc[:,1], alpha=0.2)

plt.title('Top 5 Países - Série Suavizada e Previsão SARIMA')
plt.xlabel('Data')
plt.ylabel('KG Líquido Exportado')
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left')
plt.grid(True)
plt.tight_layout()
plt.show()
```



```
avaliacoes_sarima = []

for pais in top5['pais']:
    serie = series_suavizadas[pais].sort_index().dropna()

    # Define treino e teste (últimos 12 meses para teste)
    treino = serie.iloc[:-12]
    teste = serie.iloc[-12:]

    # Ajusta SARIMA no treino
    modelo_sarima = SARIMAX(treino,
                             order=(1,1,1),
                             seasonal_order=(1,1,1,12),
                             enforce_stationarity=False,
                             enforce_invertibility=False)
    resultado = modelo_sarima.fit(dispatch=False)

    # Previsão para o período de teste
    previsao = resultado.get_forecast(steps=len(teste))
    y_pred = previsao.predicted_mean.values
    y_true = teste.values

    # Cálculo de métricas
    rmse = np.sqrt(mean_squared_error(y_true, y_pred))
    mae = mean_absolute_error(y_true, y_pred)
    mape = np.mean(np.abs((y_true - y_pred) / y_true)) * 100

    avaliacoes_sarima.append({
        'pais': pais,
        'rmse': rmse,
        'mae': mae,
        'mape_%': mape
    })

# Cria DataFrame com métricas de desempenho
df_avaliacoes_sarima = pd.DataFrame(avaliacoes_sarima)
print("\nAvaliação de desempenho do SARIMA nos Top 5 países:")
print(df_avaliacoes_sarima.sort_values('mape_%'))
```

Avaliação de desempenho do SARIMA nos Top 5 países:

	país	rmse	mae	mape_%
4	Estados_Unidos	1.880977e+08	1.704980e+08	5.141997
2	Índia	5.487190e+07	4.711570e+07	6.550801

0	China	3.942182e+09	3.038727e+09	9.991559
3	Turquia	8.247371e+08	7.884939e+08	61.499553
1	Uruguai	2.255233e+08	1.883524e+08	64.521649

Códigos aqui

6. Cronograma

O desenvolvimento do Projeto Aplicado IV foi estruturado em quatro entregas principais, cada uma com objetivos e produtos específicos.

Entrega 1 – Concepção do Tema: envolveu a formação do grupo, definição do tema e objetivos, escolha da base de dados, criação do repositório no GitHub e elaboração do documento inicial contendo introdução, justificativa, objetivos e descrição da base de dados.

Entrega 2 – Análise Exploratória e Referencial Teórico: concentrou-se na identificação dos componentes da série temporal, levantamento das técnicas de modelagem (SARIMA e XGBoost), construção do referencial teórico e desenvolvimento do pipeline inicial da solução.

Entrega 3 – Modelagem e Avaliação: compreendeu a implementação dos modelos SARIMA e XGBoost, a comparação preliminar de resultados, a realização de testes de desempenho (RMSE, MAPE, entre outros) e a documentação dos experimentos, culminando em um relatório técnico intermediário.

Entrega 4 – Consolidação Final e Apresentação: corresponde à etapa de análise comparativa entre os modelos, escolha do modelo final, discussão dos resultados obtidos, redação do relatório final em conformidade com as normas da ABNT e preparação dos slides para a apresentação do trabalho.

Entrega	Atividades	Período sugerido	Entregáveis	Status
Entrega 1 – Concepção do Tema	- Formação e organização do grupo - Definição do tema e objetivos - Escolha da base de dados - Criação do repositório GitHub - Documento inicial com introdução, justificativa, objetivos e descrição da base de dados	- Reunião dia 23/08 para definição do tema; - 23/08 à 05/08: Montagem do projeto - 06/09: Entrega	Documento inicial do projeto	Entregue
Entrega 2 – Análise Exploratória e Referencial Teórico	- Identificação dos componentes da série temporal - Levantamento das técnicas (SARIMA, XGBoost) - Escrita do referencial teórico - Pipeline da Solução	- 10/09 à 15/09: Organização da estrutura do trabalho; - 16/09 à 21/09: Referencial teórico; - 22/09 à 25/09 : Pipeline da Solução; 26/09: Entrega	Relatório parcial com análise exploratória + referencial teórico	Entregue
Entrega 3 – Modelagem e Avaliação	- Implementação do SARIMA e XGBoost - Comparação preliminar de resultados - Testes de desempenho (RMSE, MAPE, etc.) - Documentação dos experimentos - Relatório técnico intermediário	- Reunião dia 28/09 para definir os responsáveis por cada etapa; - 29/09 à 04/10: Diagrama de Solução; - EDA e Pré-processamento: 05/10 à 10/10; - 11/10 à 15/09: Modelo base; - 16/09 até a data de entrega: Revisão e Formatação.	Notebook com modelagem + relatório técnico parcial	Entregue
Entrega 4 – Consolidação Final e Apresentação	- Análise comparativa entre os modelos - Escolha do modelo final - Discussão dos resultados - Redação final do relatório (ABNT) - Preparação e entrega dos slides de apresentação	- Reunião para debater a entrega 4: 01/10	Relatório final em ABNT + slides da apresentação	Em andamento

Tabela 3: Cronograma de elaboração e controle do Projeto Aplicado IV.

Esse cronograma garantiu uma progressão lógica e estruturada do projeto, alinhando as entregas parciais ao objetivo final de desenvolver um produto analítico robusto e aplicável ao tema estudado.

7. Referências

BARBOSA, Fábio; MENEZES, Lucas. China e Brasil: transformações recentes no comércio bilateral. Revista Conjuntura Internacional, Belo Horizonte, v. 19, n. 1, p. 55-72, 2022.

BARBOSA FILHO, N. H. A crise econômica de 2014/2017. Estudos Avançados, São Paulo, v. 31, n. 89, p. 51-60, 2017. Disponível em: <https://doi.org/10.1590/s0103-40142017.31890006>. Acesso em: 27 ago. 2025.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: John Wiley & Sons, 2015.

BRASIL. Comex Stat – Estatísticas de Comércio Exterior. Disponível em: <https://comexstat.mdic.gov.br>. Acesso em: 20 ago. 2025.

BRASIL. Ministério do Desenvolvimento, Indústria, Comércio e Serviços (MDIC). Base de dados bruta – Estatísticas de Comércio Exterior. Disponível em: <https://www.gov.br/mdic/pt-br/assuntos/comercio-exterior/estatisticas/base-de-dados-bruta>. Acesso em: 20 ago. 2025.

CANO, Wilson; SILVA, Anderson. Impactos da pandemia de COVID-19 sobre o comércio exterior brasileiro. Revista de Economia Contemporânea, Rio de Janeiro, v. 25, n. 2, p. 1-20, 2021.

CASTRO, Lavínia; GIAMBIAGI, Fábio. A inserção internacional do Brasil: desafios e oportunidades na próxima década. Revista Tempo do Mundo, Brasília, v. 6, n. 2, p. 101-124, 2020.

CHATFIELD, C. The Analysis of Time Series: An Introduction. 6. ed. London: Chapman & Hall/CRC, 2003.